

Binscatter regressions文档详细总结

该文献发表于《The Stata Journal》2025 年，作者为 Cattaneo、Crump、Farrell、冯英杰，介绍 Stata 软件包**binsreg**，这套工具提供具备严谨统计理论的分箱散点 (binscatter) 方法，弥补传统 binscatter 工具统计缺陷，支持绘图、估计、不确定性分析、假设检验、最优分箱选择，适配线性、logit、probit、分位数回归等模型。

一、研究背景与动机

- 传统散点图痛点：**大数据（行政数据、社科医学数据）下普通散点图会形成密集点云，信息失效；普通散点图无法在绘图时严谨控制其他协变量。分箱散点图 (binscatter) 解决该问题，在实证微观经济学广泛使用，但早期缺少完整统计理论支撑。
- 旧 Stata 命令缺陷：**旧命令 `binscatter`、`binscatter2` 协变量调整方法存在错误，结果不一致；仅支持分段常数最小二乘绘图，**没有有效的置信区间、形状检验、组间比较、数据驱动最优分箱**等功能。其协变量调整采用“残差化”思路，只有极强假设下结果才可信，一般情况下估计量非一致。
- 本文贡献：**基于作者团队 CCFF (2024a,2024b) 理论工作，开发 `binsreg` 套件，一共 7 条 Stata 命令，统一实现估计、可视化、统计推断、最优分箱选择，提供严谨的大样本理论基础。

二、7 条核心命令总览

命令	功能
<code>binsreg</code>	最小二乘线性分箱散点：绘图、点估计、置信区间 / 置信带
<code>binslogit</code>	logit 非线性分箱散点（二元被解释变量）
<code>binsprobit</code>	probit 非线性分箱散点（二元被解释变量）
<code>binsqreg</code>	分位数回归分箱散点
<code>binstest</code>	假设检验：参数形式设定检验、非参数形状约束检验（单调性、凹凸性等）
<code>binspwc</code>	

	多组样本成对统计比较，用于 异质性处理效应分析
binsregselect	数据驱动最优分箱数量选择 器，计算 IMSE 最优分箱数

套件支持协变量调整、权重、聚类标准误、多样本分组分析；兼容 `reghdfe` 多维固定效应、`gtools` 加速大数据运算；内置质量校验（质量点 mass-point、自由度校验）保障数值稳定性。

三、方法原理

3.1 模型设定

给定样本 (y_i, x_i, w_i') ： y_i 结果变量， x_i 核心连续解释变量， w_i 控制变量向量。目标估计函数：

! 无效公式

- v 代表求导阶数， $v = 0$ 为水平函数， $v = 1$ 一阶导数；
- $\rho(\cdot)$ 损失函数， $\eta(\cdot)$ 逆连接函数；
- 可以退化为**半线性回归**、**logit/probit 二元回归**、**分位数回归**三类常用模型。

注意：模型设定错误时，估计量仅代表最小化损失函数的近似解；独立同分布假设被违背（如时间序列）时，可视化仍可运行，但估计与推断不再具备理论保证。

3.2 分箱构造

- 默认**分位数分箱**：把 x_i 取值区间切分为 J 个箱子，每个箱子样本量大致相等；也支持等距分箱、用户自定义分箱。
- 每个箱子内部使用 p 阶多项式拟合；跨箱子设置光滑约束 s ： s 代表跨箱子连续可导阶数，对应 B-样条 (B-splines) 基函数。
 - $s = 0$ ：分段多项式，箱子边界不连续，对应传统经典 `binscatter` ($p = 0, s = 0$ 即每个箱子取 y 均值)；
 - $s = 1$ ：函数在箱边界连续； $s = 2$ ：函数连续且一阶导数连续。
- 新旧协变量调整重大区别
 - 旧工具：先分别对 y 、 x 对控制变量回归取残差，再对残差做 `binscatter`（残差化方法），一般不一致；
 - `binsreg`：将样条基函数与控制变量直接放入目标损失函数联合估计，理论可靠，即使模型误设定也有清晰概率极限解释。

3.3 最优分箱数 J 选择

J 是非参数方法的调参参数，需要随样本量增大趋于无穷。套件基于**IMSE 积分均方误差准则**计算最优分箱 J_{IMSE} ，提供两种选择器：

1. $\hat{J}_{ROT}$ ：经验法则 ROT，使用参考高斯密度与全局多项式近似偏差方差，速率正确但常数项非一致估计；
2. $\hat{J}_{DPI}$ ：直接插件 DPI，使用初步估计一致估计偏差、方差常数，**程序默认 DPI**。

两种模式：

- 模式 1：给定多项式阶数 p 、光滑度 s ，选最优箱子数 J ；
- 模式 2：用户手动固定箱子 J ，反推最优多项式阶数 p 、光滑约束 s ，兼顾绘图美观与统计有效性。

经验研究者常用固定整数分箱（10/20/50/100）方便解读分位数，但是需要意识到固定 J 不一定统计最优。

3.4 置信区间、置信带与稳健偏差修正

1. **点式置信区间 CI**：针对单个 x 点的置信区间；
2. **一致置信带 CB**：对整个函数在 x 全部取值域同时推断，适合检验整体函数形态；
3. 关键问题：直接使用 IMSE 最优分箱得到的点估计存在一阶模型近似偏差，直接构造置信区间会失效。
 - 解决方案：**稳健偏差修正 Robust bias-correction**：保持原有分箱划分不变，使用更高阶多项式 $p + q (q \geq 1)$ 构造置信区间 / 置信带，消除近似偏差，保证覆盖率。
4. 方差使用三明治形式，支持聚类方差估计。置信带临界值依靠高斯模拟（从多维正态向量重复抽样）得到。

3.5 假设检验功能 (binstest)

两类检验，全部同样支持稳健偏差修正，保证一类错误可控，具备检验势：

1. **参数设定检验**：将非参数 binscatter 拟合结果与假设参数模型（常数、线性、二次多项式，外部自定义模型）对比。

 **提醒**：对函数水平 ($v = 0$) 检验结果会受协变量评估点 w 影响；推荐优先检验一阶导数 $v = 1$ 来检验线性关系，规避评估点带来的误导。

2. **非参数形状约束检验**：单侧 / 双侧检验，检验函数约束：例如函数单调、凹 / 凸、函数值不大于常数等。例如检验原假设：一阶导数 ≥ 0 （函数单调不减）。

3.6 多组比较 binspwc

支持分组 binscatter 绘图（`by()` 选项），`binspwc` 执行组间成对假设检验：原假设两组回归函数完全相等，用于研究随 x 变化的异质性处理效应。同样需要注意协变量评估点 w 对结果解读的影响。

四、实现细节与实操要点

1. **协变量评估点 `at()`**：当存在控制变量 w_i ，绘图展示条件期望可以设定评估点：均值 `at(mean)`（默认）、中位数 `at(median)`、全 0 向量，也可以外部文件自定义评估值；评估点会改变图像水平位移与置信区间。高维固定效应配合 `reghdfe absorb()` 时评估点不可自定义。
2. **质量点与自由度校验：**
 - 使用 x_i 唯一取值数目 N 作为有效样本量（不是原始观测 n ）；聚类数据则使用聚类数 G ；
 - 当有效样本不足，程序自动关闭高阶非参数推断，仅允许简单分段常数估计，给出警告；
 - 选项 `masspoints()`、`dfcheck()` 可以修改校验规则。
3. **提速技巧（大数据）**
 - 将数据预先按照 x 排序；
 - x 连续无重复值：`masspoints(off)` 关闭质量点校验；
 - 手动给定 `nbins()`，避免自动数据驱动选箱；
 - 安装 `gtools` 配合 `usegtools(on)`；高维固定效应使用 `reghdfe`；
 - 模拟次数 `nsims()`、网格点 `simsgrid()` 调低用于初步探索。
4. **绘图选项：**`dots(p s)` 设置散点点，`line(p s)` 拟合曲线，`ci(p s)` 点置信区间，`cb(p s)` 一致置信带，各个元素可以使用不同 **p、s** 参数，实现稳健偏差修正；可以导出绘图数据 `savdata()`；支持标准 `twoway` 绘图选项美化图表。

五、模拟示例

使用自带模拟数据集 `binscatter_simdata.dta` 演示：

1. **基础估计绘图：**`binsreg y x w`，自动 DPI 选择分箱，输出分箱散点图；可以增加 `line()`、`ci()`、`cb()` 添加拟合线、置信区间、置信带；`polyreg(P)` 叠加全局多项式；`vce(cluster id)` 聚类标准误；`by(t)` 分组绘图。
2. **分位数回归：**`binsqreg` 实现条件分位数 `binscatter`，可以 `bootstrap` 标准误。
3. **二元 Logit 模型：**`binslogit` 处理 0-1 被解释变量。
4. **检验示例**
 - `binstest y x w, testmodelpoly(1)` 检验函数是否线性；
 - `deriv(1) testshaper(0)` 检验函数单调不减；
 - `binspwc y x w, by(t)` 两组函数是否存在差异。
5. **binsregselect：**输出 ROT、DPI 两套最优分箱；`savegrid()` 输出网格文件，用于外部自定义模型的设定检验；`randcut()` 用随机子样本加速分箱选择。

六、局限与未来拓展方向

1. **现有局限**：主要面向横截面数据；仅支持单变量 x 作为分箱变量。
2. **未来拓展方向**：面板数据、时间序列 `binscatter`；多维分箱与热力图，把本套统计推断框架拓展到多维可视化场景。

七、软件安装

Stata 安装：

代码块

```
1 net install st0765
2 net sj 25-1
3 net get st0765
```

项目主页：<https://nppackages.github.io/binsreg/>

八、核心启示给实证研究者

1. 传统 `binscatter` / `binscatter2` 协变量残差化方法统计不可靠，建议优先使用 `binsreg`；
2. 只看图不做检验存在误导风险，应当配合 `binstest` 做正式形状、参数设定检验；检验线性优先检验一阶导数而非水平值；
3. IMSE 最优分箱兼顾偏差方差；人为固定分箱数（如 20）牺牲统计最优换取可读性，需要权衡；
4. 置信带（uniform confidence band）和点置信区间含义完全不同；做全函数推断要使用置信带；
5. 协变量条件下，图像高度、检验结果依赖协变量评估点 `at()`，解读结果必须关注该设定。

如果你需要，我可以进一步整理**binsreg 常用 Stata 代码速查表**。

（注：部分内容可能由 AI 生成）