

Nonlinear Binscatter Methods (RESTAT, 2026) 详细总结

本文是 Cattaneo-Crump-Farrell-冯英杰系列 binscatter 工作的第三篇核心论文，拓展 AER (2024) 线性最小二乘 binscatter 理论，建立**非线性、非光滑 M-估计框架下的分箱散点方法**，覆盖 logit/probit、分位数回归、稳健回归；提供最优分箱选择、一致置信带、形状 / 参数假设检验、多组异质性比较，配套 Stata/R/Python 的 `binsreg` 软件实现。

三篇文献分工：

1. AER 2024: **线性最小二乘 binscatter 理论基础**；
2. Stata Journal 2025: **软件操作手册**；
3. RESTAT 2026 本文: **非线性 binscatter 理论 (logit、probit、分位数回归)**。

一、研究背景与动机

1. binscatter 在社科、健康、金融领域广泛用于大数据可视化，但**原有理论与工具只支持最小二乘条件均值估计**，存在明显局限：
 - 无法处理离散 / 分数被解释变量（0-1 二元结果）；
 - 不能刻画条件分布的离散度、分位数，只能看条件均值；
 - 缺少针对 logit、probit、分位数回归这类 M-估计的严谨统计理论、最优调参、置信带、假设检验。
2. 已有非参数序列 / 划分估计文献**不能直接套用到 binscatter**：
 - binscatter 普遍使用**分位数分箱（随机断点、随机基函数）**，旧文献大多假设断点固定已知；
 - 分位数回归损失函数是非光滑的，旧理论条件过强，不支持 piecewise-constant（分段常数，经典 binscatter）。
3. 本文贡献
 - a. 提出通用非线性 M-估计分箱散点框架，兼容广义线性模型、分位数回归、稳健回归；
 - b. 推导随机分箱下的一致 Bahadur 表示、条件高斯强近似（核心技术创新）；
 - c. 给出 IMSE 最优分箱数 J_{IMSE} 选择规则，适配非线性损失函数；
 - d. 开发点式 + **一致置信带**、参数设定检验、非参数形状约束检验、多组成对比较；
 - e. 实证示例：美国 ACS 人口普查数据，研究**人均收入与无医保人口占比（分数被解释变量）**；

f. 全部方法集成到 `binsreg` 软件包，对应命令 `binslogit`、`binsprobit`、`binsqreg`。

二、模型设定

给定独立同分布样本 (y_i, x_i, w_i') ：

- y_i ：被解释变量，可以连续、二元、分数；
- x_i ：核心连续处理变量；
- w_i ：控制变量向量，维度可以随样本发散（ $d \rightarrow n$ ，但不允许个体固定效应）。

目标模型（半线性结构）：

$$(\mu_0(\cdot), \gamma_0) = \arg \min_{\mu \in \mathcal{M}, \gamma \in \mathbb{R}^d} \mathbb{E} [\rho(y_i; \eta(\mu(x_i) + w_i' \gamma))]$$

- $\rho(\cdot; \cdot)$ ：损失函数； $\eta(\cdot)$ ：逆连接函数；
- $\mu_0(x)$ ： x 的非参数函数；控制变量 w_i 是线性可分，不与 x 交互。

三大核心目标估计量

1. **水平函数**： $\vartheta_0(x, w) = \eta(\mu_0(x) + w' \gamma_0)$ ：固定控制变量取值 w ， y 的条件期望 / 条件分位数；
2. **非参数部分及其导数**： $\mu_0^{(v)}(x) = \frac{d^v}{dx^v} \mu_0(x)$ ：用于检验函数形态（线性、单调性、凹凸）；
3. **边际效应**： $\zeta_0(x, w) = \eta^{(1)}(\mu_0(x) + w' \gamma_0) \cdot \mu_0^{(1)}(x)$ ：非线性模型下 x 的局部边际效应。

w 为评估点，常用均值 `at(mean)`、中位数 `at(median)`、基准类别 0；评估点会改变图像位置、置信带形状、检验结果，解读时必须注意。

代表性模型实例

1. **最小二乘（线性 binscatter）**： $\rho(y; \eta) = (y - \eta)^2$ ， $\eta(\theta) = \theta$ ；
2. **Logit 二元 / 分数模型**：对数似然损失， $\eta(\theta) = \frac{1}{1 + \exp(-\theta)}$ ，适合 0-1 被解释变量；
3. **分位数回归**： $\rho(y; \eta) = \ell_\tau(y - \eta)$ （检验损失函数，非光滑）， $\eta(\theta) = \theta$ ，用于研究条件分布不同分位数，刻画离散程度、异质性。

注意：线性最小二乘 binscatter 容易对分数结果产生超出 $[0,1]$ 区间的拟合值；logit-binscatter 天然把预测限制在 0-1 之间。

三、估计方法

1. **分箱划分**：将 x_i 支撑划分为 J 个箱子 $\widehat{\mathcal{B}}_j$ ，默认**分位数分箱**（每个箱子样本量大致相等）；理论同时支持等距分箱，要求分箱只依赖 x ，**不能使用 y 信息（随机划分条件）**。
2. **基函数构造**：
 - 每个箱子内部 p 阶多项式；跨箱子施加 $s-1$ 阶连续约束； $p \geq s \geq 0$ ；

- $s = 0$ ：箱子边界不连续； $s = p$ 对应 B-样条；经典 binscatter $p = 0, s = 0$ 分段常数。
- 基函数 $\hat{b}_{p,s}(x) = \hat{T}_s(\hat{b}_0(x) \otimes [1, x, \dots, x^p]')$ ； $\hat{T}_s$ 施加光滑约束。

3. 广义 M-估计，联合估计非参数部分与控制变量系数，不做预先残差化：

$$\begin{bmatrix} \hat{\beta} \\ \hat{\gamma} \end{bmatrix} = \arg \min_{\beta, \gamma} \sum_{i=1}^n \rho \left(y_i; \eta(\hat{b}_{p,s}(x_i)' \beta + w_i' \gamma) \right)$$

关键：不能分箱内单独回归，因为 γ 是**全局系数**，必须整体联合优化。

由此得到三个估计量：

两种看待 J （分箱数）的视角：

1. J 固定：只能估计粗粒度箱内对象，适合按十分位 / 百分位做分组对比；**不能检验底层连续函数的形态（线性、单调性）**；
2. $J \rightarrow \infty$ **随样本发散**：非参数视角，用来一致估计真实连续函数，用于检验函数形式，本文理论主要讨论该情形。

四、理论贡献（第 3 章）

面向应用的读者可跳过数学细节。

本文两大核心理论定理，允许**随机分箱（分位数分箱）、非线性 / 非光滑损失、控制变量维度可发散**。

1. 定理 1：一致 Bahadur 表示

在全部 x 支撑上给出估计量的随机线性展开。这是推导方差、MSE 展开、分布近似的基础。

- 突破 AER2024 仅适用于最小二乘的限制；
- 允许随机生成的分箱基函数，不要求断点收敛到固定非随机值；
- 对分位数回归这类非光滑损失同样成立，速率条件比旧文献宽松。

2. 定理 2：可行条件高斯强近似（feasible strong approximation）

得到学生化 t-统计量随机过程的条件高斯耦合。

- 作用：模拟获取上确界统计量的临界值，构造**一致置信带、全域假设检验**；
- 技术特点：不要求基函数收敛到非随机总体对象，适配 binscatter 的随机分位数分箱；相比现有序列估计文献，速率条件显著更宽松，可以处理经典分段常数 binscatter。

五、调参：最优分箱数量 J 选择（第 4 章）

1. IMSE（积分均方误差）分解，平衡偏差平方与方差，得到 IMSE 最优分箱：

$$J_{IMSE}(p) := \left(\frac{2(p+1)\mathcal{B}_n(p)}{\mathcal{V}_n(p)} \right)^{\frac{1}{2p+3}} n^{\frac{1}{2p+3}}$$

- $\mathcal{B}_n(p)$ ：渐近偏差项； $\mathcal{V}_n(p)$ ：渐近方差项；

- 该公式推广到非线性 M-估计，软件 `binsregselect` 实现 ROT 经验法则、DPI 直接插件两种可行估计。

注意：IMSE 最优 J 对点估计最优，但会残留一阶近似偏差，**不能直接拿来推断，必须使用稳健偏差修正 Robust Bias-Correction (RBC)**：保持分箱 $\widehat{\Delta}$ 不变，用更高阶多项式 $p + q (q \geq 1)$ 构造推断。

六、统一推断：置信带与假设检验（第 5 章）

6.1 一致置信带 Confidence Band

区别于单点置信区间 CI，**置信带同时对全部 $x \in \mathcal{X}$ 有效，用于评价整个函数形态。**

- 流程：采用 IMSE 最优 J 做点估计；保持分箱不变，提升多项式阶数 $p + 1$ 构造稳健偏差修正置信带；
- 临界值：基于强近似结果，从多维正态分布重复模拟得到；
- 理论性质： $\mathbb{P} \left[\vartheta_0(x, w) \in \hat{I}_{\vartheta, p+1}(x), \forall x \in \mathcal{X} \right] \rightarrow 1 - \alpha$ 。

重要实操提醒：

- 评估点 w 会改变置信带位置、宽度；
- 偏差修正后，IMSE 最优点估计**有可能落在置信带外面**，数学上合法，只是视觉不美观。

6.2 假设检验

支持三类全域（sup-norm 上确界）检验：

- 参数设定检验**：检验 $\mu_0(x)$ 是否服从某参数形式（线性、三次多项式）；
- 形状约束检验**：检验单调性、凹凸性（例如一阶导数 ≤ 0 单调递减原假设）；
- 多组成对比较**：检验不同组别目标函数是否完全相等，识别随 x 变化的异质性处理效应。

检验同样使用稳健偏差修正，控制一类错误，具备检验势。

6.3 多组样本比较

- 允许分组估计每个组的 $\vartheta_{0,t}(x, w)$ ；
- 检验原假设：所有 x 下两组函数完全相等；
- 用途：离散处理的异质性效应、连续处理剂量-反应函数跨组对比；同样受评估点 w 影响。

七、实证示例：ACS 美国社区调查数据

被解释变量：zip 码层级无医保人口占比（分数 0-1）；核心变量：人均收入。

- 基础 logit-binscatter**：

- 人为指定 $J = 10$ （主观选择）得到的图会过度平滑，掩盖 Medicaid 医疗补助带来的真实非线性；
- IMSE 自动最优 $J = 81$ ，还原真实形态：低收入区间无医保率先上升，随收入提高再下降；**拒绝线性、拒绝单调递减**；
- 当样本限制在 Medicaid 资格收入门槛之上，不能拒绝单调递减，但依旧拒绝多项式参数形式。

2. 分位数 binscatter:

估计 10%、50%、90% 条件分位数，可以可视化**条件分布离散程度**：低收入地区无医保率的跨区域差异巨大，加入人口统计控制变量后离散度收窄。

3. **边际效应图**：画出 x （收入）的局部边际效应及其置信带，可以看到边际效应符号会发生改变。

4. **分组对比**：按人口密度划分高低密度州，检验两组医保-收入关系是否存在显著差异。

附录补充演示

1. **抗异常值能力**：中位数 binsqreg 对少量异常值稳健，而最小二乘 binsreg 会被污染；
2. **模型对比**：线性最小二乘 binscatter 对分数结果会产生 < 0 的不合理预测；logit-QMLE binscatter 的预测始终落在 0-1 区间；
3. **区分两个“不确定性”**：
 - 置信带：估计量本身抽样不确定性；
 - 分位数曲线：刻画**数据条件分布本身的离散程度**，二者概念完全不同。

八、与旧 binscatter 工具的关键启示

1. 传统 binscatter / binscatter2 只有最小二乘分段常数；**不能做 logit、probit、分位数回归 binscatter**；
2. 非线性模型**禁止预先对 y 、 x 做残差化再绘图**；必须把分箱基与控制变量放入同一个 M-估计损失联合求解；
3. 做函数形态（线性、单调性）检验，不能仅凭肉眼看图，需要：IMSE 最优分箱 + 稳健偏差修正的**一致置信带 / binstest 正式检验**；
4. 非线性 binscatter 要时刻关注 `at()` 评估点的选择，评估点会改变水平、边际效应、置信带与检验结果；
5. 固定 $J = 10/20/50$ 只适合分组对比，**不适合检验底层连续回归函数的形态**。

九、局限与未来拓展

1. 当前理论仅支持单变量 x 作为非参数部分，暂不支持多维非参数（二维热力图）；
2. 不允许维度随样本发散的个体固定效应（面板个体 FE）；
3. 未来可以拓展：多维 binscatter 热力图、时序数据 binscatter。

软件包：<https://github.com/nppackages/binsreg>

命令对应：`binslogit`、`binsprobit`、`binsqreg`，配合 `binstest`、`binspwc`、`binsregselect`。

如果你需要，我可以帮你整理一份**非线性 binscatter 实操避坑清单 + Stata 代码片段**。

（注：部分内容可能由 AI 生成）