

《On Binscatter》（AER,2024）详细总结

这是 Cattaneo、Crump、Farrell、冯英杰发表于 *American Economic Review* 2024 的理论论文，是 `binsreg` 软件包对应的核心理论基础，系统剖析分箱散点图（binscatter）的统计性质，指出传统 binscatter 的致命缺陷，建立严谨的非参数理论框架，提供最优分箱、稳健偏差修正、一致置信带、假设检验工具，并通过两篇经典实证文献重新分析展示方法的实际影响，配套提供 Stata/R/Python 开源实现。

配套 Stata Journal 2025 文章是软件操作手册，本篇为原始理论论文。

一、研究背景与动机

- binscatter 的流行**：大数据下原始散点图会变成密集点云，可读性差；binscatter 将核心变量 x 划分为 J 个箱子，绘制每个箱子内 y 的均值，用于可视化 y 与连续变量 x 的条件期望关系，在应用微观经济学广泛使用，常用于判断函数形式（线性、单调性、凹凸性），指导后续回归设定。
- 现有实践的重大隐患**
 - 传统 binscatter（`binscatter` / `binscatter2`）处理控制变量时普遍使用**残差化法（residualized binscatter）**：先把 y 和 x 分别对控制变量回归取残差，再对残差做分箱散点。论文证明该方法**一般不具备一致性**，会扭曲条件期望的形状、改变变量支撑区间，导致看图得出错误结论，只有在真实关系严格线性的特殊条件下才有效。
 - 经验上随意设定分箱数量 J （固定取 10、20、50、100），没有平衡偏差-方差权衡。
 - 缺少正式不确定性量化：仅有图上的点，没有同时对整个回归函数有效的统计推断工具，仅靠肉眼看图做判断不严谨。
- 本文贡献**
 - 将 binscatter 严格形式化为**基于划分的非参数估计量**，给出数学定义；
 - 提出**正确的协变量调整半线性 binscatter**，替代错误的残差化流程；
 - 给出基于 IMSE（积分均方误差）的数据驱动最优分箱选择规则；
 - 开发**稳健偏差修正的一致置信带（confidence band）**，实现对整个条件期望函数的同时推断，区别于单点置信区间；
 - 建立全新大样本理论，处理“分位数分箱（随机断点）”带来的技术难点，弥补旧非参数理论不能适配实证常用随机分箱的缺陷；
 - 用已发表的两篇经典实证文章复现分析，展示错误 binscatter 会如何改变实证结论；
 - 发布跨平台软件实现（Stata/R/Python binsreg 工具包）。

二、传统 binscatter 与残差化方法的缺陷

2.1 标准（无控制变量）canonical binscatter

把 x 的样本按样本分位数切分为 J 个箱子 $\hat{\mathcal{B}}_j$ （分位数分箱，每个箱子样本量大致相等）。每个箱子计算 y 样本均值： $\bar{y}_j$ ，绘制 $(\bar{x}_j, \bar{y}_j)$ 。

数学等价于**0 阶分段常数最小二乘序列回归**：

$$\hat{v}(x) = \hat{b}(x)' \hat{\xi}, \quad \hat{\xi} = \arg \min_{\xi \in \mathbb{R}^J} \sum_{i=1}^n \left[y_i - \hat{b}(x_i)' \xi \right]^2$$

$\hat{b}(x)$ 是指示变量向量，标记观测落入哪一个箱子。

注意：图上离散的点本质是分段常数函数的采样，不是原始数据点。

2.2 广为误用的残差化协变量调整

传统做法：

1. y 对常数、 w_i 回归取残差 $\tilde{y}_i$ ；
2. x 对常数、 w_i 回归取残差 $\tilde{x}_i$ ；
3. 对 $(\tilde{x}_i, \tilde{y}_i)$ 做标准 binscatter。

理论问题：该估计收敛到

$$E[y_i - L(y_i|w_i) \mid x_i - L(x_i|w_i)]$$

这个对象**并不等于我们关心的条件期望** $E[y_i|x_i = x, w_i = w]$ 。

- 即使真实模型满足半线性设定 $E[y_i|x_i, w_i] = \mu_0(x) + w_i' \gamma_0$ ，残差化 binscatter 依旧一般不能一致估计 $\mu_0(x)$ ；
- 会扭曲函数形状，压缩 / 改变 x 轴取值范围；
- 不能用来可靠检验线性、单调性；非线性真实关系有可能看图表现为线性，线性真实关系看图表现为非线性，误导研究者。

论文给出解析例子 + 真实数据复现佐证该偏差。

2.3 论文提出的正确协变量-调整 binscatter

采用**半线性模型框架**，把分箱基函数与控制变量放进同一个最小化目标函数联合估计，不做预先残差化：

$$\begin{bmatrix} \hat{\beta} \\ \hat{\gamma} \end{bmatrix} = \arg \min_{\beta, \gamma} \sum_{i=1}^n \left[y_i - \hat{b}(x_i)' \beta - w_i' \gamma \right]^2$$

目标参数：固定控制变量到某评估点，最常用取协变量样本均值 $\bar{w}$

$$\hat{\Upsilon}(x) = \hat{\mu}(x) + \bar{w}' \hat{\gamma}$$

对应估计 $\Upsilon_0(x) = \mu_0(x) + E[w_i]' \gamma_0$ ，代表**控制协变量取均值条件下**， x 对 y 的条件均值，有清晰解释。

关键点：

1. 评估点 w 可以自定义（中位数、基准类别 0 等），评估点的选择会改变图像位置与统计推断结果；

2. 即使半线性模型设定错误，估计量依旧解释为最优均方近似；
3. 当 w_i 与 x_i 均值独立时， $\Upsilon_0(x) = E[y_i|x_i]$ 。

三、分箱数量 J 的选择：偏差-方差权衡

J 是 binscatter 核心调参：

- J 过小：箱子宽，**偏差大**，过度平滑，掩盖真实函数形态；
- J 过大：箱子窄，每个箱子样本少，**方差爆炸**，图像抖动剧烈。

两种看待 J 的视角

1. **固定 J 视角**： J 人为给定（如 $J = 10$ 对应十分位），目标估计每个箱子内条件期望，适合仅做分组对比；**不能用来检验函数整体形态（线性、凹凸）**。
2. **非参数估计视角**：要恢复连续函数 $\Upsilon_0(x)$ ， J 需要随样本量发散 $J \rightarrow \infty$ ，实现一致估计，适合检验函数形式。

IMSE 最优分箱 J_{IMSE}

基于积分均方误差 IMSE 展开，平衡平方偏差与方差，对于经典 piecewise-constant binscatter ($p = 0, s = 0$)：

$$J_{IMSE} = \left\lceil \left(\left(\frac{2\mathcal{B}_n}{\mathcal{V}_n} \right)^{1/3} n^{1/3} \right) \right\rceil$$

- $\mathcal{B}_n$ ：渐近偏差； $\mathcal{V}_n$ ：渐近方差；
- 论文给出可行 DPI 数据驱动估计方法，软件 `binsregselect` 实现；
- 最优 J 受异方差、聚类、控制变量影响。

实践提示：即使你为了视觉好看用固定 J ，也可以拿 IMSE-最优 J 做基准，判断当前 J 是过平滑还是欠平滑。

四、不确定性量化：置信带 Confidence Band

区分两个概念：

1. **点式置信区间 CI**：仅针对单个 x 点；
 2. **一致置信带 CB**：同时对 x 全部支撑域有效，可以用来可视化检验整个函数的形状（论文重点）。
1. 问题：直接使用 IMSE 最优 J 做估计会存在**一阶近似偏差**，直接构造区间会失效。论文采用**稳健偏差修正 Robust Bias-Correction (RBC)**：保持原来分箱划分不变，提升多项式阶数构造推断，不需要改变 bins。

2. 置信带形式：

$$\hat{I}_{RBC}(x) = \left[\hat{\Upsilon}_{BC}(x) \pm \mathfrak{c}_{RBC} \cdot \sqrt{\hat{\Omega}_{RBC}(x)/n} \right]$$

- $\mathfrak{c}_{RBC}$ ：通过条件高斯强近似，模拟多维正态随机向量获取临界值；
- 理论保证： $\Pr\left(\Upsilon_0(x) \in \hat{I}_{RBC}(x), \forall x \in \mathcal{X}\right) \rightarrow 1 - \alpha$ 。

置信带实证用途

- 如果某条函数（例如直线、水平线）**完全落在置信带内部**，不能拒绝该函数形式；
- 如果完全不能放入，则拒绝该函数形式（例如拒绝线性、拒绝没有关系）。

若使用固定 J ，推断对象变为离散箱参数 Ξ_0 ，此时不需要偏差修正，但该置信带不能用来推断底层连续回归函数。

五、实证复现（两篇已发表论文）

案例 1：Akcigit et al.(2022)，税收与创新

原始论文用传统残差化 binscatter，原始图存在支撑压缩、扭曲。

1. 传统残差绘图视觉上呈现非线性；
2. 使用本文正确协变量-adjust binscatter+IMSE 最优 $J = 11$ ，加上 95% 稳健置信带；
3. **线性函数完全落在置信带内部，不能拒绝线性**，支持原文线性回归设定。

案例 2：Moretti (2021)，高科技集聚与发明者生产率

1. 原始残差 binscatter 图看起来近似线性；
2. 使用正确方法 + IMSE 最优 $J = 18$ ，置信带结果：**拒绝线性、拒绝水平（无效应）**，不能拒绝凸函数；
3. 经济含义：集聚效应是非线性；只有集群规模足够大，专利产出才会明显提升。小集群补贴很难产生大的集聚收益，这是原文没有发现的重要经济学洞见。

两个案例直观展示：**协变量处理方式会实质性改变 binscatter 的实证结论**。

六、理论贡献（第五部分）

传统非参数序列估计理论**不能直接适配 binscatter**，原因：

1. binscatter 最常用**分位数分箱**：箱子断点是样本统计量（随机的），生成随机基函数；旧理论大多假设断点固定已知。
2. 经典 binscatter 是 piecewise-constant ($p = 0$)，很多序列估计理论对平滑度要求高，不适用。

本文主要理论成果：

1. 拓展估计量到一般形式：每个箱子内 p 阶多项式，跨箱子施加 $s-1$ 阶连续约束（B 样条），允许估计函数各阶导数；

$$\hat{\mu}^{(v)}(x) = \hat{b}_{p,s}^{(v)}(x)' \hat{\beta}, \quad \begin{bmatrix} \hat{\beta} \\ \hat{\gamma} \end{bmatrix} = \arg \min \sum_{i=1}^n \left[y_i - \hat{b}_{p,s}(x_i)' \beta - w_i' \gamma \right]^2$$

2. 推导带随机分箱的 IMSE 渐近展开，得到最优调参 $J_{IMSE}(p, s, v)$ ；
3. 建立**条件高斯强近似（conditional strong approximation）**，这是构造一致置信带的核心数学工具；绕过随机基函数带来的一致性障碍，只需要宽松的样本量速率条件，允许经典 piecewise-constant binscatter。
4. 给出模拟获取上确界统计量临界值的可实施算法，软件实现。

在线附录给出全部证明、拓展，包含 L_p 距离检验等其他度量。

七、论文结论与启示

1. binscatter 是强大可视化工具，但**不能简单“看图说话”**；协变量处理、分箱选择、不确定性量化缺一不可。
2. **✗**坚决避免旧的残差化（residualized）binscatter 做带控制变量的图形分析，容易得到误导结论。
3. 优先采用联合估计的半线性协变量调整；注意评估点 `at()` 会改变图形解读。
4. 想要检验函数形态（线性、单调性），要把 binscatter 当作非参数估计，采用数据驱动 IMSE 最优 J ，搭配**稳健偏差修正的置信带**；固定 J 只能做箱内均值对比，不适合检验整体函数形态。
5. 肉眼看图不能替代统计推断；置信带提供正式可视化检验。
6. 本文理论框架仅针对单变量 x 条件均值；配套后续论文拓展到分位数、logit/probit 非线性模型，对应 Stata Journal 软件手册。
7. 开放软件：<https://nppackages.github.io/binsreg/>

八、和 Stata-Journal 2025 软件手册的关系

- **AER (2024) 本文：理论论文**，解释“为什么旧 binscatter 错，新方法数学原理，大样本性质，实证危害”；
- **Stata Journal (2025)：软件操作手册**，讲解 7 条命令 `binsreg binslogit binsprobit binsqreg binstest binspwc binsregselect` 的语法、选项、实操例子；
两者是一套工作：AER 讲理论，SJ 讲软件实操。

如果你需要，我可以帮你整理一份**binscatter 实证避坑清单**，或者对比新旧 binscatter 的关键差异表格。

（注：部分内容可能由 AI 生成）